



НАУЧНАЯ ТРОПА ИННОПОЛИСА

Кажется, что понимает

Один тип ошибки — от лошади до облака

Алан Тьюринг в 1950 году предложил не спорить, умеет ли машина думать, — вопрос он считал слишком туманным, — а заменить его проверяемым. Посадить судью переписываться вслепую с человеком и с машиной, и пусть угадает, кто из них кто¹. Не угадывает — машину засчитывают за разумную. Проверка вышла поведенческой: судят не по тому, что у собеседника внутри, а по тому, как он отвечает.

ELIZA показала, в чём здесь подвох. Исход зависит и от машины, и от судьи, а человек слишком охотно засчитывает понимание. Вейценбаум потом сформулировал это одной мыслью: программа показывает, как легко создать и поддержать иллюзию понимания.

То же свойство замечали задолго до компьютеров. В начале XX века по Германии гремел конь Умный Ганс — он отстукивал копытом ответы на арифметические задачи, и публика верила, что лошадь считает. В 1907 году психолог Оскар Пфунгст устроил проверку и выяснил: считать конь не умеет². Он улавливал невольные движения спрашивающего — лёгкое напряжение в позе и лице по мере того, как копыто доходило до верного числа, и расслабление в нужный момент. Стоило задать вопрос так, чтобы ответа не знал и сам спрашивающий, и Ганс ошибался. Ум был в комнате, только не в лошади.

В самом мягком виде это знакомо каждому: лицо, проступающее в облаке, в розетке, в подгоревшем тосте. Мозг держит быстрый детектор лиц, настроенный на чувствительность: ему выгоднее принять случайные пятна за лицо, чем пропустить настоящее³. Цена ошибки несимметрична — не заметить хищника в кустах опаснее, чем вздрогнуть от тени, — поэтому детектор откликается на слабый намёк.

Эффект ELIZA, Умный Ганс, лицо в облаке — срабатывания одного механизма, настроенного видеть лица, агентов и умыслы при первом же поводе. Мы скорее увидим разум, которого нет, чем пропустим тот, что есть.

¹А. М. Turing, «Computing Machinery and Intelligence». Mind LIX(236), 433–460 (1950) — «имитационная игра» (тест Тьюринга): вопрос «может ли машина мыслить» заменён проверяемой игрой в различение (doi:10.1093/mind/LIX.236.433).

²Oskar Pfungst, «Das Pferd des Herrn von Osten (Der Kluge Hans)» (1907). Конь реагировал на невольные телесные сигналы спрашивающего; когда ответа не знал и человек, Ганс ошибался — «эффект умного Ганса» (Wikipedia, «Clever Hans»).

³Парейдолия — склонность мозга видеть осмысленные образы (особенно лица) в случайных стимулах; объясняется «дешёвым» гиперчувствительным детектором лиц с несимметричной ценой ошибки (Wikipedia, «Pareidolia»).