



НАУЧНАЯ ТРОПА ИННОПОЛИСА

Кажется, что понимает

Что на самом деле измеряет тест

Тьюринг предсказывал, что к 2000 году машина в пятиминутной беседе будет обманывать судью достаточно часто — настолько, что разговоры о «мыслящих машинах» станут привычными. Точнее, что верно опознавать собеседника судья будет не чаще чем в 70% случаев. Прогноз сбился с опозданием. В 2025 году Кэмерон Джонс и Бенджамин Берген (Калифорнийский университет в Сан-Диего) провели контролируемый трёхсторонний тест: судья пять минут параллельно переписывался с человеком и с программой, а затем называл, кто из двоих человек¹.

Результат говорит сам за себя в сравнении:

Собеседник	Принят за человека
GPT-4.5, с указанием держаться роли	73%
GPT-4.5, без такого указания	36%
GPT-4o (прежнее поколение)	21%
ELIZA (1966)	23%

Современную модель GPT-4.5, которой велели держаться человеческой роли, судьи приняли за человека в 73% случаев — чаще, чем настоящего собеседника-человека. Это первое строгое свидетельство, что машина проходит классический тест Тьюринга. А сама ELIZA, проигрывая, делает результат убедительным: раз её узнают как машину почти всегда, высокие баллы модели — не просто общая людская склонность всё очеловечивать. Тест, как видно, удостоверяет неотличимость в разговоре, а не мышление; а неотличимость — это факт и про машину, и про судью.

Две машины, два устройства

ELIZA устроена просто. Она ищет в реплике ключевое слово, по жёстко прописанному правилу разбирает фразу на части и собирает ответ обратно, переставляя местоимения: «я» на «вы», «моё» на «ваше». Весь её «разум» — несколько сотен строк таких правил и заготовок; ни модели мира, ни памяти о сказанном за пределами текущей фразы. Нет ключевого слова — в ход идут безопасные заглушки вроде «расскажите подробнее».

Современная модель устроена иначе и куда тяжелее. Её не программируют правилами вручную: её обучают предсказывать следующее слово в тексте, прогнав

¹Cameron R. Jones, Benjamin K. Bergen, «Large Language Models Pass the Turing Test» (2025), UC San Diego. В контролируемом трёхстороннем тесте GPT-4.5 с инструкцией держать роль принимали за человека в 73% случаев (arXiv:2503.23674).



через неё громадные объёмы написанного людьми. Из одной этой задачи — угадать продолжение — вырастают миллиарды настроенных чисел, в которых осели закономерности языка. Отвечает она, выбирая вероятное продолжение разговора. Снаружи оба собеседника держат одну сторону беседы; внутри между ними пропасть.

Проходит — значит ли понимает?

Тест проверяет неотличимость в разговоре, а не понимание, и одно из другого не вытекает. Философ Джон Сёрл возразил мысленным опытом о «китайской комнате»: человек, не знающий китайского, по толстому своду правил выдаёт на китайские записки безупречные китайские ответы — снаружи он будто сдаёт экзамен на язык, внутри не понимает ни иероглифа². Так и прохождение теста, по этому доводу, говорит об убедительности ответов, но не о понимании за ними. Спор этот не закрыт.

Сами авторы теста замечают: высокий балл — про социальную убедительность, а не про ум. И добавляют деталь: без подсказки держаться роли модель набирает заметно меньше — те же 36% против 73%. Казаться человеком она умеет, а вот сообразить сама, каким человеком надо казаться, выходит хуже.

Как это измеряют

Чтобы отделить настоящую неотличимость от поспешного очеловечивания, тест ставят как контролируемый опыт: судья сравнивает машину не саму по себе, а бок о бок с живым человеком; вопросы и роли оговорены заранее; в набор включают слабую программу-приманку (ту самую ELIZA). Если приманку распознают, а сильную модель нет — дело не в одной людской доверчивости. Это прямая родня проверке Пфунгста: тот тоже не поверил молве про коня, а развёл спрашивающего и животное и менял, кто из людей знает ответ.

Открытый вопрос

Если в беседе машина уже неотличима от человека, что остаётся надёжным признаком мысли — и есть ли он вообще? И по мере того как имитация крепнет, эффект ELIZA нас выручает или подводит: готовность видеть в собеседнике своего помогает ладить с машинами — или мешает разглядеть, что перед нами лишь складно подобранные слова?

²John Searle, «Minds, Brains, and Programs». Behavioral and Brain Sciences 3(3), 417–457 (1980) — мысленный эксперимент «Китайская комната»: синтаксис (манипуляция символами) не даёт семантики (понимания) (Stanford Encyclopedia of Philosophy, «The Chinese Room Argument»).